

Systemy złożone i analiza danych

Sprawozdanie z 7. zadania

Mieszko Czubiński

Nr albumu: 284047

23 września 2026

1 Projekt algorytmu

1.1 Algorytm

Celem algorytmu jest **wykrywanie anomalii** krawędzi w sieci społecznej. Anomalią nazywamy krawędź, która łączy bezpośrednio dwie peryferyjne postacie, mimo że bez tej krawędzi byłyby one od siebie oddalone o wiele kroków (czyli normalnie komunikowałyby się przez łańcuch hubów). Jednym z zastosowań jest wykrywanie krawędzi, które prawdopodobnie nie powinny być powstać. Wskazane krawędzie można usunąć z sieci albo potraktować jako sygnał wymagający bliższej analizy.

Punktem wyjścia było proste pytanie: na ile dana krawędź jest „skrót”? Aby to zmierzyć, można porównać bezpośrednie połączenie z najlepszą alternatywą – usunąć krawędź (u, v) i sprawdzić, ile kroków trzeba pokonać, żeby dotrzeć z u do v inną drogą. W sieci społecznej połączonej hubami takie „skrót” mają również krawędzie pomostowe między samymi hubami, co jest naturalne. Jako, że komunikacja zwykle przebiega przez huby, anomalią jest dopiero bezpośrednie połączenie dwóch peryferyjnych wierzchołków. Dlatego do długości objazdu dołączono peryferyjność obu końców (oparta na hubowości). W skrócie: zamiast „jak długi objazd” sprawdzamy „jak długi objazd między peryferiami”.

1.2 Schemat działania

Algorytm dla każdej krawędzi (u, v) liczy wynik $\text{score}(u, v)$ łączący długość objazdu z peryferyjnością obu końców:

1. **Hubowość.** Dla każdego wierzchołka wyznaczamy $\text{hubness}(n) \in [0, 1]$ jako rangę jego stopnia, znormalizowaną do przedziału $[0, 1]$ (najsłabszy wierzchołek 0, najsilniejszy 1).
2. **Objazd.** Krawędź (u, v) jest tymczasowo usuwana, a następnie liczona jest długość najkrótszej ścieżki $u \rightarrow v$ w pozostałym grafie (hops). Jeśli nie ma alternatywnej trasy – krawędź jest pomijana.
3. **Peryferyjność.** $\text{periph}(u, v) = (1 - \text{hubness}(u)) \cdot (1 - \text{hubness}(v))$. Wartość bliska 1 oznacza dwa peryferyjne końce; bliska 0 – że któryś z końców jest hubem.

4. **Wynik.** $\text{score}(u, v) = \text{hops} \cdot \text{periph}$. Wysoki, gdy długi objazd oraz peryferyjne końce.
5. **Próg.** Krawędzie sortujemy malejąco po wyniku; jako anomalie oznaczamy górny odsetek.

1.3 Inne rozwiązania

Problem wskazywania „nietypowych” krawędzi można zrealizować również kilkoma prostymi, powszechnie znanymi metodami:

- **Mosty (bridges).** Krawędź, której usunięcie rozspaja graf na dwie części (funkcja `nx.bridges`). Wykrywa jedynie skrajny przypadek – krawędzie, które nie mają żadnej alternatywnej trasy.
- **Odwrócona predykcja połączeń.** Klasyczne miary podobieństwa wierzchołków (Common Neighbors, Jaccard) szacują, jak prawdopodobna jest krawędź. Istniejąca krawędź o bardzo niskim wyniku jest nieoczekiwana.

2 Implementacja

2.1 Technologie

Algorytm stworzono w języku Python, wykorzystując biblioteki `NetworkX` oraz `NumPy`. Do wyświetlenia danych użyto biblioteki `Seaborn`.

2.2 Implementacja

Rdzeń algorytmu przedstawia listing 1. Funkcja `compute_hubness` wyznacza hubowość, `detour_hops` liczy długość objazdu po usunięciu krawędzi, a `detect_anomalies` składa wyniki, sortuje krawędzie i oznacza górny odsetek jako anomalie.

```
def compute_hubness(G):
    deg = dict(G.degree())
    order = sorted(deg, key=lambda n: deg[n])
    n = len(order)
    if n <= 1:
        return {node: 1.0 for node in order}
    return {node: rank / (n - 1) for rank, node in
            enumerate(order)}

def detour_hops(G, u, v):
    data = dict(G[u][v])
    G.remove_edge(u, v)
    try:
        d = nx.shortest_path_length(G, u, v)
    except nx.NetworkXNoPath:
        d = None
    G.add_edge(u, v, **data)
    return d
```

```

def detect_anomalies(G, top_frac=TOP_FRAC):
    hub = compute_hubness(G)
    rows = []
    for u, v in list(G.edges()):
        d = detour_hops(G, u, v)
        if d is None:
            continue
        periph = (1.0 - hub[u]) * (1.0 - hub[v])
        rows.append({'u': u, 'v': v, 'hub_u': hub[u], 'hub_v':
                    hub[v], 'hops': d, 'periph': periph, 'score': d *
                    periph})

    rows.sort(key=lambda r: r['score'], reverse=True)
    n_anom = round(top_frac * len(rows))
    thr = rows[n_anom - 1]['score'] if 0 < n_anom <= len(rows)
        else float('inf')
    for i, r in enumerate(rows):
        r['significant'] = i < n_anom

    return {'hubness': hub, 'edges': rows, 'top_frac': top_frac,
            'threshold': thr}

```

Listing 1: Rdzeń algorytmu wykrywania anomalnych krawędzi.

3 Testy i wyniki

Algorytm uruchomiono na sieci rzeczywistej (graf relacji postaci sagi o wiedźminie, zbudowany ze współwystąpień w tekście) oraz na sieci losowej Barabási–Albert (BA) o tej samej liczbie wierzchołków i zbliżonej liczbie krawędzi. Model BA wybrano jako odniesienie, ponieważ jest najbliższy strukturalnie sieci społecznej.

Tabela 1 przedstawia dziesięć wierzchołków o najwyższej hubowości w sieci rzeczywistej. Tabela 2 zawiera dziesięć krawędzi o najwyższym wyniku score; widać, że oba końce każdej z nich mają niską hubowość (peryferia), a długość objazdu wynosi 4–6 kroków.

Postać	hubness
Geralt of Rivia	1.0000
Ciri	0.9979
Yennefer	0.9958
Emhyr var Emreis	0.9937
Falka	0.9916
Philippa Eilhart	0.9895
Vilgefortz	0.9874
Triss Merigold	0.9853
Milva	0.9832
Jarre	0.9811

Tabela 1: Dziesięć wierzchołków o najwyższej hubowości w sieci rzeczywistej.

Postać 1	Postać 2	hubness _u	hubness _v	objazd	preferencyjność	score
Ilona Laux-Antille	Yolenta Suarez	0.273	0.275	6	0.528	3.166
Ilona Laux-Antille	Leticia Charbonneau	0.273	0.277	6	0.526	3.157
Leticia Charbonneau	Jada Glevissig	0.277	0.279	6	0.522	3.130
Aurora Henson	Herbert Stammelford	0.254	0.256	5	0.555	2.777
Aurora Henson	Ivo Richert	0.254	0.258	5	0.554	2.769
Yanna of Murivel	Klara Larissa de Winter	0.262	0.264	5	0.543	2.715
Orestes Kopps	Istvan Igalffy	0.323	0.367	6	0.429	2.572
Cairbre aep Diared	Orestes Kopps	0.463	0.323	6	0.363	2.181
Marquard	Rejean	0.268	0.270	4	0.534	2.135
Vascoigne	Istvan Igalffy	0.468	0.367	6	0.337	2.023

Tabela 2: Dziesięć krawędzi o najwyższym wyniku w sieci rzeczywistej.

Natomiast Tabela 3 przedstawia wierzchołki o najwyższej hubowości w sieci BA. A Tabela 4 zawiera dziesięć krawędzi o najwyższym wyniku score.


Wierzchołek	hubness
4	1.0000
0	0.9979
11	0.9958
6	0.9937
10	0.9916
7	0.9895
13	0.9874
9	0.9853
5	0.9832
16	0.9811

Tabela 3: Dziesięć wierzchołków o najwyższej hubowości w sieci BA.


Wierzchołek 1	Wierzchołek 2	hubness _u	hubness _v	objazd	preferencyjność	score
30	213	0.373	0.034	4	0.606	2.423
135	198	0.403	0.023	4	0.584	2.335
100	265	0.388	0.073	4	0.567	2.269
115	269	0.396	0.078	4	0.557	2.228
176	219	0.426	0.038	4	0.553	2.211
191	390	0.438	0.218	5	0.439	2.197
175	416	0.423	0.258	5	0.428	2.139
197	253	0.444	0.061	4	0.522	2.087
202	429	0.449	0.279	5	0.398	1.988
155	341	0.415	0.153	4	0.495	1.982

Tabela 4: Dziesięć krawędzi o najwyższym wyniku w sieci BA.


Rozkład wyników wszystkich krawędzi (posortowanych malejąco) wraz z progiem odcięcia przedstawiają rysunki 1 (sieć rzeczywista) i 2 (sieć BA). Wykryte anomalie na tle całej sieci pokazują rysunki 3 i 4.




Rysunek 1: Sieć rzeczywista: wynik score krawędzi wg rangi oraz próg (górny 1%).



Rysunek 2: Sieć Barabásiego–Alberta: wynik score krawędzi wg rangi oraz próg (górny 1%).



Rysunek 3: Sieć rzeczywista z zaznaczonymi anomaliami (kolor czerwony).



Rysunek 4: Sieć Barabásiego–Alberta z zaznaczonymi anomaliami (kolor czerwony).

4 Ocena algorytmu

Porównanie obu sieci zestawia tabela 5. Przy tym samym odsetku odcięcia (1%) sieć rzeczywista i sieć BA dają podobną liczbę anomalii, jednak **próg odcięcia w sieci BA jest wyraźnie wyższy** (1.927 wobec 1.555). Wynika to ze struktury: w sieci BA brak społeczności, więc peryferyjne wierzchołki są realnie dalej od siebie i większość krawędzi ma wyższy wynik. W sieci rzeczywistej społeczności trzymają peryferia blisko własnego huba, więc krawędzie „normalne” mają niski wynik, a prawdziwe skróty wybijają się już przy niższym progu.

Miara	Sieć rzeczywista	Sieć BA
Wierzchołki	478	478
Krawędzie ocenione	1550	1425
Próg score (top 1%)	1.555	1.927
Liczba anomalii	16	14

Tabela 5: Porównanie wyników działania algorytmu na sieci rzeczywistej i losowej (BA).

5 Wnioski

Zaproponowany algorytm skutecznie wskazuje krawędzie będące dalekosieżnymi skrótami między peryferiami sieci, omijające huby. Jest prosty (kilka funkcji), w pełni topologiczny i samodostrajający się. Testy na sieci rzeczywistej i losowej pokazały, że wyniki są zgodne z intuicją.